In [3]:

Introduction to Data Analysis With PANDAS

C'est quoi Pandas?

- Pandas est une bibliothèque construite au-dessus du langage Python
- · Chaque bibliothèque a sa propre orientation ou spécialité
- Pandas est spécialisé sur l'analyse des données
 - C'est une boîte à outils robuste : analyser, filtrer, manipuler, aggréger, concatener, netoyer, etc.
 - En gros, il s'agit de EXCEL de Python

Quelques librairies pour le traitement de données

1. Apache Spark

- Stars: 27600, Commits: 28197, Contributors: 1638
- Apache Spark A unified analytics engine for large-scale data processing

2. Pandas

- Stars: 26800, Commits: 24300, Contributors: 2126
- Pandas is a Python package that provides fast, flexible, and expressive data structures
 designed to make working with "relational" or "labeled" data both easy and intuitive. It
 aims to be the fundamental high-level building block for doing practical, real world data
 analysis in Python.

3. Dask

- Stars: 7300, Commits: 6149, Contributors: 393
- · Parallel computing with task scheduling

https://www.kdnuggets.com/2020/11/top-python-libraries-data-science-data-visualization-machine-learning.html?

utm_content=166184627&utm_medium=social&utm_source=linkedin&hss_channel=lcp-3740012

Pré-requis

- · Connaissances basiques sur le fonctionnement des tableurs
 - Notions de colonnes, lignes
- Connaissances sur le typage des données
 - String, integers, boolean, float, etc.

Recommendations

- Connaissances avancées sur le fonctionnement des tableurs
 - Fonctions, pivoter, etc.
- Connaissances basiques sur le langage de programmation Python
 - Fonctions, variables, typage de variables, etc.
 - Nb: je vous recommanderai de faire un tour sur excel pour voir ces differentes fonctions avant, si vous n'avez aucune notion sur les tableurs

À propos de ce cours

- · Subdivisé en plusieurs modules
 - chaque module abordera une fonctionnalité spécifique
- Un ensemble de données, au format CSV (Comma-separated values) pour les différents cas d'étude
 - bien évidement, on pourrait aborder le traitement de tout type de fichier, à votre demande

Pour commencer

- 1. Python et Pandas doivent être installé sur votre PC
 - La plus facile des options, serait d'installer la distribution du paquet Anaconda
 - qui intègre non seulement python et pandas, mais aussi plus +100 autres librairies d'analyse de données
- 2. Un terminal/ligne de commande pour les mises à jours et l'installation de nouvelles librairies
- 3. editeur: Jupiter-notebook

Explorons Jupyter-notebook

- · les différentes parties/sections
- · séquences d'exécutions
- · commentaires
- appel à de fonctions externes

Basic Data Types

- · Python est un langage orienté Objet
 - le paradigme orienté Objet: programme logiciel est une collection d'objets qui communiquent entre eux
 - C'est quoi un Objet ?

 type de donnée abstraite pouvant prendre en compte la notion de polymorphisme et de l'héritage

- structure numérique, un conteneur pouvant stocker une sorte d'informations
- tout est objet en Python: Object <=> structure de données sous Python

```
In [4]:
         # integer
Out[4]:
In [5]:
         # flaoting point number
         2.5
Out[5]: 2.5
In [6]:
         # String
          "Michel"
          "3"
Out[6]:
In [ ]:
In [7]:
         # boolean, toujours utilisés pour evaluer une situation donnée
         True
         False
          'M' in "Michel"
          2>8
        False
Out[7]:
In [8]:
         None # s'il n'y a rien à returner/afficher
In [9]:
         print('')
        Opérateurs
In [10]:
         # example on integer objects
         3+3
Out[10]: 6
In [11]:
         # concatenation
          'FD' + 'IA'
```

```
#FD' - 'IA'
                                          \times = 'FD ' * 10
                                                 = x.split(' ')
Out[11]: ['FD', 'FD', 'F
In [12]:
                                      [v for v in y if v]
Out[12]: ['FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD', 'FD']
In [13]:
                                      |# poids des opérateurs (PEMDAS => Parentheses Exponents
                                         Multiplication Division Addition Substraction)
                                         2 + 4 * 5
Out[13]: 22
In [14]:
                                      # division
                                          5/3
Out[14]: 1.666666666666667
In [15]:
                                      10 // 5
Out[15]: 2
In [16]:
                                      5 % 3
Out[16]: 2
In [17]:
                                      14 / 3
Out[17]: 4.66666666666667
In [18]:
                                         round(14 / 3,2)
Out[18]: 4.67
In [19]:
                                      4.67 * 3
Out[19]: 14.01
In [20]:
                                      #equality
                                           x'' == 2
Out[20]: False
```

```
In [21]: # Inequality
```

Variables

• nom attribué à un objet dans un programme

Built-in function

- procedure or sequence of step
- example : len(), str(), int(), float(), type(), etc.

Custom function

- · custum function are build to answer a specific needs
- funtion name should discribe what the function is doing

```
# function that accepts temperature in Celcius and returns it in
Fahrenheit
def convert_to_fahrenheit(celcius_temp):
    fahrenheit = celcius_temp * 1.8 + 32
    return fahrenheit
# set default value
def convert_to_fahrenheit(celcius_temp = 0):
    fahrenheit = celcius_temp * 1.8 + 32
    return fahrenheit
```

```
##
# we can combine build-in with custom function
def addition(n):
    return n + n

# example
numbers = (1, 2, 3, 4)
result = map(addition, numbers)
print(list(result))
```

[2, 4, 6, 8]

```
In [24]: # using multi-build-in function
numbers1 = [1, 2, 3]
numbers2 = [4, 5, 6]

result = map(lambda x, y: x + y, numbers1, numbers2)
result
list(result) # retourner la nouvelle donnée sous forme de list
```

```
Out[24]: [5, 7, 9]
```

In []:

String methods

- specific function that belong to a specific object
- a method is directely uppon on an object
- contary to a function, a method is directly associated to an object ### QUIZ
- · difference between:
 - buit-in function
 - custom fonction
 - method

```
In [25]: # example
    profession = " fd and ai student "
    profession.capitalize()
    profession.title()
    profession.lstrip()
    profession.rstrip()
    profession.split()
```

```
Out[25]: ['fd', 'and', 'ai', 'student']
```

```
In [26]: age = 40
age.bit_length
```

Out[26]: <function int.bit_length()>

Lists

- mutable
- · to keep data in some ordered places

```
In [27]: ##
my_list = ['first', 'one', 'two', 'second']
```

NB

- remove() delete the matching element/object whereas del and pop removes the element at a specific index.
- del and pop deals with the index. The only difference between two is that- pop return deleted the value from the list and del does not return anything.
- Pop is only way that returns the object.
- Remove is the only one that searches object (not index). Which is the best way to delete the element in List?
- If you want to delete a specific object in the list, use remove method.
- If you want to delete the object at a specific location (index) in the list, you can either use del or pop.
- Use the pop, if you want to delete and get the object at the specific location.

Index positions and slicing

```
In [31]: # string index
    name = 'boukary'
    len(name)

Out[31]: 7

In [32]:    name[6]
    name[-1]

Out[32]: 'y'

In [33]:    student_list = ['kabore', 'ilboudo', 'kafando', 'robgo']

In [34]:    # first index position, and the last one that we want to stop. the first index will be include in the result student_list[1:3]
```

```
Out[34]: ['ilboudo', 'kafando']
In [35]:
          student list[:-3]
Out[35]: ['kabore']
        dictionnary
          · unordered collection of key-values pair

    association between two elments or linked-data

In [36]:
         # restaurant menu
          menu = {'rice': 300, 'fish':600, 'pizza': 6000, 'salmon': 7000}
In [37]:
          menu
Out[37]: {'rice': 300, 'fish': 600, 'pizza': 6000, 'salmon': 7000}
In [38]:
          # add another speciallity, use pop() to delete
          menu['meat'] = 500
In [39]:
          menu
Out[39]: {'rice': 300, 'fish': 600, 'pizza': 6000, 'salmon': 7000, 'meat': 500}
In [40]:
          menu.values()
Out[40]: dict values([300, 600, 6000, 7000, 500])
In [41]:
          menu.keys()
Out[41]: dict_keys(['rice', 'fish', 'pizza', 'salmon', 'meat'])
In [42]:
          menu.items()
Out[42]: dict_items([('rice', 300), ('fish', 600), ('pizza', 6000), ('salmon', 7000),
         ('meat', 500)])
In [43]:
          l = [1,2,3]
          x = ['a','b','c']
Out[43]: {1: 'a', 2: 'b', 3: 'c'}
In [ ]:
```

In []:	
In []:	
In [130	
In [3]:	
In [4]:	
In []:	